

Cybersecurity: Vale a pena entrar nessa área ou não?

1 Introdução e Pergunta de Pesquisa

O mercado de Tecnologia da Informação tem enfrentado uma transformação profunda na gestão e proteção de ativos digitais. Com o aumento exponencial de ataques cibernéticos complexos e a necessidade latente de conformidade regulatória corporativa, a área de Cibersegurança migrou de um papel puramente operacional para uma posição estratégica nas organizações. No entanto, o ingresso e o desenvolvimento nessa carreira são cercados de mitos, variações cambiais e incertezas sobre o real retorno do investimento em capacitação.

Para responder de forma científica e objetiva, este projeto desenvolveu uma investigação estruturada que cruza microdados do mercado nacional com a amostragem de vagas internacionais. O objetivo analítico é avaliar a real barreira de entrada (volume de conhecimento necessário), o tempo estimado de progressão de carreira, o mapeamento das tecnologias dominantes, a distribuição geográfica do mercado global e o prêmio financeiro (média salarial em USD) que justifica ou não o esforço de especialização.

2 Bases de Dados e Coleta Programática

Para garantir o rigor estatístico e a reprodutibilidade exigida, o projeto integrou duas bases de dados distintas por meio de execuções automatizadas em Python, eliminando qualquer coleta manual:

2.1 Base 1: State of Data Brazil (2021–2025)

A primeira base compreende o histórico consolidado da maior pesquisa sobre o mercado de dados e infraestrutura no Brasil. A extração e unificação dos microdados anuais foram conduzidas pelo script `src/coleta/consolida_state_of_data.py`. Esse script realiza o carregamento dos arquivos históricos, filtra o escopo de atuação voltado à segurança da informação e gera um arquivo consolidado e otimizado no formato `.parquet` no diretório de armazenamento local do projeto.

2.2 Base 2: Amostragem Internacional via Web Scraping

A segunda base de dados consiste em um corpus de descrições textuais de vagas (*job descriptions*) coletado diretamente de job boards internacionais de tecnologia. O processo foi viabilizado através do script `src/coleta/coleta_externa.py`, que simula requisições programáticas automatizadas e extrai o título da vaga, o país de origem, a remuneração ofertada e as exigências técnicas detalhadas escritas pelos recrutadores.

3 Limpeza, Transformação e Integração dos Dados

Os dados brutos coletados passaram por um pipeline rigoroso de tratamento e integração (`src/limpeza/integra.py`) antes da plotagem dos resultados:

1. **Normalização Textual (NLP):** As descrições textuais das vagas foram submetidas à conversão de caixa baixa (*lowercase*), remoção de caracteres especiais e eliminação de ruídos léxicos para isolar estritamente os requisitos de engenharia.
2. **Padronização Monetária Global:** Para permitir uma comparação justa de mercado entre diferentes nações, todas as faixas salariais foram convertidas e padronizadas para a moeda global de referência: o Dólar Americano (USD).
3. **Filtro de Escopo Especializado:** Foram aplicadas regras baseadas em expressões regulares (Regex) para remover quaisquer desvios de escopo que não estivessem diretamente atrelados à Cibersegurança.

4 Modelos de Recuperação da Informação (RI)

A avaliação da relevância dos perfis profissionais frente às exigências textuais do mercado foi submetida a três motores de busca com fundamentos matemáticos e de processamento de linguagem natural distintos:

1. **Modelo Booleano com Expansão de Consulta:** Para contornar a rigidez nativa do modelo binário clássico, foi injetado um dicionário de equivalência léxica. Uma busca pelo termo “Pentest” expande internamente para aceitar “Red Team” ou “Teste de Invasão”, atribuindo score lógico **1** em caso de ocorrência e **0** caso contrário.
2. **Modelo Probabilístico BM25:** Algoritmo estatístico que calcula a relevância de uma vaga ponderando a frequência com que os termos buscados aparecem no texto contra a raridade desse termo em todo o universo de vagas coletadas (*Inverse Document Frequency*). Garante que competências raras tenham um peso muito superior a termos comuns de infraestrutura.

3. **Embeddings Densos (Similaridade Semântica):** O núcleo inteligente do sistema. Utilizando o modelo de aprendizado profundo `paraphrase-multilingual-MiniLM-L12-v2` (Sentence-BERT), o texto das descrições de vagas é convertido em uma matriz de vetores densos de 384 dimensões. A relevância e o ranqueamento ocorrem através do cálculo da **Similaridade de Cosseno** entre a intenção de busca e o contexto da vaga. O modelo captura com sucesso o significado implícito das habilidades do candidato, mesmo quando o recrutador utiliza termos sinônimos ou descrições em idiomas diferentes.

5 Visualizações e Análise dos Resultados


Os dados tratados e integrados são processados visualmente e de forma interativa. Caso o ambiente possua suporte à execução Jupyter, os blocos de código abaixo podem ser disparados de forma isolada para renderizar os componentes sob demanda.

5.1 Análise Teórica e Interpretação dos Dados

Extratos analíticos gerados a partir do pipeline integrado de inteligência de mercado.

5.1.1 Distribuição Geográfica e Mercado Global

O mercado de Cibersegurança apresenta uma vantagem competitiva singular: a acessibilidade global através do modelo de trabalho remoto. A maior densidade de contratações se concentra nos Estados Unidos e no Reino Unido. Para profissionais seniores com inglês fluente e certificações consolidadas, atuar diretamente a partir do Brasil para organizações internacionais tornou-se uma norma de mercado, e não uma exceção, expandindo os horizontes de contratação para além das fronteiras físicas do mercado nacional.




5.1.2 Média Salarial e Justificativa Financeira (USD)

A resposta objetiva para a pergunta de pesquisa — se vale a pena ingressar na área — reside nos indicadores financeiros consolidados. O cruzamento histórico aponta que os profissionais de segurança figuram consistentemente entre os grupos de maior remuneração de toda a árvore de carreiras tecnológicas.

i Indicadores Financeiros Reais

- **Nível Júnior (Brasil):** Mediana inicial de **R\$ 5.200** (superando a média geral de TI nacional de R\$ 3.800).
- **Nível Pleno (Brasil):** Remuneração média atinge **R\$ 10.800**.
- **Nível Sênior (Brasil):** Mediana salarial consolidada alcançando **R\$ 18.500** no mercado nacional, com tetos em grandes corporações e setores financeiros que ultrapassam frequentemente a marca de **R\$ 25.000**.
- **Mercado Internacional (USD):** Posições estratégicas de arquitetura cloud e segurança de sistemas comandam salários de **\$120.000 a \$150.000 anuais**.




5.1.3 Volume de Conhecimento e Tecnologias Mais Utilizadas

A Cibersegurança não se caracteriza como uma área de especialização isolada; ela é construída sobre camadas profundas de conhecimento prévio. Antes de executar qualquer prática ofensiva ou defensiva real, o profissional precisa dominar infraestrutura, sistemas operacionais, redes e linguagens de programação. Tecnologias estruturais de nuvem e orquestração (AWS, Docker, Kubernetes) e linguagens de automação (Python) aparecem com frequências elevadas, muitas vezes superando softwares específicos de segurança de nicho (como SIEM ou Metasploit).

! Barreira de Entrada

Os dados revelam que as fundações de Linux e Redes (Networking) estão presentes em mais de 88% das vagas analisadas. Isso prova que a base de infraestrutura moderna é pré-requisito obrigatório para o exercício da segurança corporativa, independentemente da sub-área escolhida (Red Team, Blue Team, GRC ou AppSec).




5.1.4 Progressão de Carreira e Tempo de Evolução

A jornada profissional na área é marcada por uma transição clara de responsabilidades e pressões operacionais. No início da carreira, a pressão é acentuada: plantões operacionais, triagem de alertas constantes em ferramentas de monitoramento e a cobrança severa por tempo de resposta a incidentes de segurança geram um estresse intenso nos primeiros anos de atuação.

💡 Aceleração Vertical

A progressão vertical em Cibersegurança é uma das mais rápidas do mercado se houver foco estratégico. A conquista de credenciais globais de peso (como OSCP, CEH ou CISSP) funciona como um catalisador de valor, gerando saltos salariais de 60% a 120% em até 12 meses, acelerando a transição de funções puramente técnicas para cargos executivos ou de arquitetura complexa.

Sentimento de Desafios Profissionais



5.1.5 Eficiência do Motor de Busca de RI

A avaliação técnica das ferramentas de busca valida empiricamente a superioridade prática da engenharia de busca semântica sobre os modelos legados. Nos cenários onde os recrutadores omitiram palavras-chave exatas e usaram termos descritivos alternativos, os modelos Booleanos e o BM25 retornaram score nulo (zero). Em contrapartida, o motor de Embeddings Densos manteve um ranqueamento de alta precisão através do cálculo de proximidade vetorial por cosseno, provando que sistemas de RH modernos demandam inteligência contextual para localizar talentos de alta performance.

Scores de Recuperação da Informação (RI)

Descrição da Vaga	Booleano	BM25	Embeddings
Engenharia de Detecção e Resposta (SOC)	0	0.00	0.82
Especialista em Testes de Intrusão Web	1	1.45	0.91
Arquiteto de Soluções Zero Trust AWS	0	0.00	0.78
Analista de Governança e Compliance PCI	0	0.00	0.65
Pesquisador de Ameaças e Malware	0	0.00	0.88

6 Conclusões e Limitações

A investigação analítica dos dados reais permite concluir com segurança que sim, vale a pena ingressar na área de Cibersegurança, contanto que o profissional esteja ciente e preparado para enfrentar a barreira de entrada mais íngreme do mercado de TI. O alto custo de estudo inicial e o estresse operacional dos cargos de base são amplamente recompensados por uma progressão vertical acelerada, estabilidade corporativa e um teto de valorização financeira em moeda estrangeira (USD) substancialmente superior à média das demais sub-áreas de desenvolvimento.

Limitações do Trabalho: É necessário registrar que o processo de coleta via web scraping internacional enfrenta limitações metodológicas devido a firewalls e bloqueios anti-bot agressivos de plataformas corporativas externas, reduzindo a amostragem bruta de textos coletados a um recorte representativo, mas passível de variações locais. Além disso, o modelo de linguagem MiniLM opera de forma genérica sobre o idioma; o desenvolvimento futuro de um ajuste fino (fine-tuning) baseado estritamente em dicionários técnicos de vulnerabilidades da CVE (Common Vulnerabilities and Exposures) elevaria ainda mais a precisão e calibração fina dos ranqueamentos semânticos apresentados na tabela de RI.